PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS

Engenharia de Software

Medição e Experimentação em Engenharia de Software, 2º semestre de 2026

Trabalho Final, Parte 1: Protocolo do Survey

Tema: uso de métricas DORA em times com pipelines CI/CD

Integrantes: Davi Érico dos Santos, Gabriel Felipe Santos de Sousa, João Vitor Santana Lopes, Lucas Alves Resende e Pedro Maia da Costa Silva

Repositório: https://github.com/JoaoSantanaLopes/survey-dora-cicd

1. Objetivo e questões de pesquisa

Queremos entender se os times que já têm pipeline de CI/CD acompanham de fato as métricas DORA (frequência de deploy, lead time para mudanças, taxa de falha em mudanças e tempo de restauração do serviço) e o que as pessoas desses times acham delas. O objetivo segue o template do GQM:

GQM	Definição
Analisar	o uso das métricas DORA
Com o propósito de	caracterizar a adoção e avaliar a utilidade percebida
Com respeito a	quais métricas são acompanhadas, como são coletadas e o quanto são vistas como úteis e confiáveis
Do ponto de vista de	desenvolvedores, pessoal de DevOps/SRE e líderes técnicos
No contexto de	times de software no Brasil que usam pipelines CI/CD

A partir desse objetivo definimos três questões de pesquisa:

QP1: Quais métricas DORA os times com pipelines CI/CD acompanham de fato e como elas são coletadas?

QP2: A adoção das métricas DORA está associada ao porte da empresa?

QP3: A utilidade percebida das métricas DORA muda conforme o papel do respondente e conforme o número de métricas que o time acompanha?

As métricas de cada questão estão na tabela abaixo. A M9 não responde a nenhuma QP: ela descreve quem respondeu e alimenta os filtros do dashboard.

QP	Métricas
QP1	M1: percentual de respondentes cujo time acompanha cada métrica DORA. M2: percentual por forma de coleta. M3: percentual por finalidade de uso. M4: índice de confiança nos dados (média de 3 itens Likert). M8: frequência com que o time consulta as métricas.
QP2	M5: percentual de adoção (o time acompanha pelo menos uma métrica) em cada faixa de porte.
QP3	M6: índice de utilidade percebida (média de 4 itens Likert). M7: quantidade de métricas DORA acompanhadas (de 0 a 4).
Perfil	M9: distribuição da amostra por papel, tempo de experiência, porte da empresa e ferramenta de CI/CD.

2. População e amostragem

A população-alvo são profissionais de software que trabalham no Brasil em times que usam CI/CD, como desenvolvedores, DevOps/SRE, QA ou líderes técnicos. Logo no começo do formulário perguntamos se o time da pessoa usa CI/CD; quem responde "Não" ou "Não sei" é encerrado ali. Colegas da turma ficam fora da amostra, porque o público é de profissionais. Eles participam só do pré-teste (seção 4), cujas respostas não entram na análise.

Os contatos virão da rede de cada integrante: LinkedIn, colegas de trabalho e de estágio, grupos de desenvolvedores no WhatsApp, Telegram e Discord e ex-alunos do curso. A amostragem não é probabilística. Vamos usar conveniência junto com bola de neve, pedindo para quem responder repassar o link para outras pessoas da área.

Queremos chegar a 100 respostas válidas, com mínimo de 50. A margem de erro foi calculada para uma proporção com 95% de confiança, no pior caso (p = 0,5), pela fórmula $e = 1{,}96 \times \sqrt{p(1 - p) / n}$:

n (respostas válidas)	Margem de erro
50	± 13,9 pontos percentuais
75	± 11,3 pontos percentuais
100	± 9,8 pontos percentuais

Quando um resultado se referir a um subgrupo (por exemplo, uma faixa de porte), a margem será calculada com o n daquele subgrupo e será maior. Como a amostra é por conveniência, a margem serve só de referência: ela não garante que os resultados representem todos os times com CI/CD do país.

3. Questionário

O questionário tem 20 itens, está no Google Forms e deve levar cerca de 7 minutos (o tempo medido no pré-teste está na seção 4). Cada item está ligado a uma QP e a uma métrica. Antes das perguntas sobre uso há uma explicação curta de cada métrica DORA, para que todos respondam pensando na mesma coisa.

Bloco 0: consentimento e filtro

Item	Pergunta	Opções	Escala	QP / Métrica
C1	Você leu o termo acima e concorda em participar?	Sim / Não ("Não" encerra o formulário)	Nominal	Controle
F1	O time em que você trabalha hoje usa pipeline de CI/CD?	Sim / Não / Não sei ("Não" e "Não sei" encerram)	Nominal	Filtro

Bloco 1: perfil

Item	Pergunta	Opções	Escala	QP / Métrica
P1	Qual é o seu papel principal no time?	Desenvolvedor, DevOps/SRE/Plataforma, QA, Líder técnico ou gestor, Outro	Nominal	QP3 / M9
P2	Há quanto tempo você trabalha com software?	Menos de 1 ano; de 1 a menos de 3; de 3 a menos de 5; de 5 a menos de 10; 10 anos ou mais	Ordinal	M9 (filtro)
P3	Quantas pessoas trabalham na empresa?	Até 49, 50 a 249, 250 a 999, 1000 ou mais, Não sei	Ordinal	QP2 / M5, M9
P4	Qual é a principal ferramenta de CI/CD do time?	GitHub Actions, GitLab CI, Jenkins, Azure DevOps, Outra	Nominal	M9

Bloco 2: uso das métricas

Item	Pergunta	Opções	Escala	QP / Métrica
U0	Seu time acompanha alguma dessas quatro métricas?	Sim / Não / Não sei	Nominal	QP1 / M1, QP2 / M5
U1	Quais delas o time acompanha? (pode marcar mais de uma)	Frequência de deploy, Lead time, Taxa de falha, Tempo de restauração	Nominal (cada opção) e razão (contagem)	QP1 / M1, QP3 / M7
U2	Como essas métricas costumam ser coletadas?	Automaticamente por ferramenta, Parte automática e parte manual, Manualmente (planilha ou similar), Por estimativa, Não sei	Nominal	QP1 / M2
U3	Com que frequência o time olha essas métricas?	Menos de uma vez por mês, Mensalmente, Quinzenalmente, Semanalmente, Diariamente	Ordinal	QP1 / M8
U4	Para que as métricas são usadas? (pode marcar mais de uma)	Melhorar o processo, Metas do time, Relatórios para a gestão, Avaliar pessoas, Não sei	Nominal	QP1 / M3

U1 a U4 e os itens de confiança (CD1 a CD3) só aparecem para quem responde "Sim" na U0. O Google Forms não desvia o fluxo a partir de uma pergunta de múltipla seleção como a U1, e por isso a U0 faz esse desvio. Quem responde "Não" na U0 conta como zero métricas (M7 = 0). Quem responde "Não sei" fica fora da QP2 e da correlação da QP3, mas aparece na parte descritiva.

Bloco 3: afirmações em escala Likert (1 = discordo totalmente, 5 = concordo totalmente)

Item	Afirmação	Construto	QP / Métrica
UP1	As métricas DORA ajudam um time a encontrar gargalos na entrega.	Utilidade percebida	QP3 / M6
UP2	As métricas DORA ajudam a tomar decisões sobre o processo.	Utilidade percebida	QP3 / M6
UP3	Acompanhar as métricas DORA compensa o esforço.	Utilidade percebida	QP3 / M6
UP4*	As métricas DORA fazem pouca diferença no dia a dia de um time.	Utilidade percebida	QP3 / M6
AT1	Para mostrar que está lendo com atenção, marque "Discordo totalmente" nesta linha.	Atenção	Controle
CD1	Os valores das métricas mostram a realidade do meu time.	Confiança nos dados	QP1 / M4
CD2	Os dados usados nas métricas vêm de fontes confiáveis.	Confiança nos dados	QP1 / M4
CD3*	Eu desconfio dos números que as métricas mostram.	Confiança nos dados	QP1 / M4

* itens invertidos

Os itens de utilidade são respondidos por todos, inclusive por quem não acompanha nenhuma métrica, e por isso falam de "um time" e não do time da pessoa. No formulário, cada construto fica numa grade, e a pergunta de atenção fica no meio da grade de utilidade.

Bloco 4: pergunta aberta (opcional)

A1: Qual é a maior dificuldade para usar essas métricas no seu time? Se o time não usa, conte por quê. As respostas serão codificadas em categorias (nominal) e complementam a QP1.

4. Pré-teste

O pré-teste foi feito em 12/11/2026 com três pessoas, todas colegas da turma, dando preferência a quem trabalha ou faz estágio em time com CI/CD. Como a turma não faz parte da amostra, essas respostas não se misturam com as da coleta. Cada pessoa respondeu pelo link do formulário e depois nos contou quanto tempo levou, o que ficou confuso, se faltou alguma opção e se as explicações das métricas ficaram claras. Antes de abrir a coleta, as respostas do pré-teste foram separadas numa planilha à parte e apagadas do formulário.

Participante	Papel	Tempo de resposta	Problema encontrado	O que mudamos
1	Desenvolvedor	4 min	Achou confusa a passagem da pergunta "Seu time acompanha alguma dessas métricas?" para as opiniões sobre elas, e não soube como opinar sem conhecer as métricas	Na abertura da seção de opinião, explicamos que quem não conhece bem as métricas deve responder pelo que entendeu da explicação e, sem opinião, marcar "Nem concordo nem discordo"
2	Desenvolvedor	9 min	Nenhum	Nenhuma
3	Desenvolvedor	6 min	Nenhum	Nenhuma

O tempo ficou entre 4 e 9 minutos, perto dos 7 minutos informados no termo. Uma pessoa respondeu "Sim" na U0 e duas responderam "Não", e nas respostas os desvios funcionaram como planejado. As três acertaram a pergunta de atenção. Uma das pessoas cujo time não acompanha as métricas marcou "Concordo totalmente" nos quatro itens de utilidade, inclusive no invertido. Na coleta, a regra de padrão repetido da seção 5 descartaria essa resposta, então mantivemos a regra e o item invertido como estavam.

5. Plano de análise

Antes da análise vamos limpar os dados e anotar o motivo de cada descarte. Uma resposta é descartada se: a pessoa não aceitou o termo; o time não usa CI/CD ou a pessoa não sabe; errou a pergunta de atenção; marcou o mesmo valor em todos os itens de utilidade e de confiança, inclusive nos invertidos (a pergunta de atenção não entra nessa conta); ou a resposta é duplicada. Como o formulário não pede login, consideramos duplicadas as respostas idênticas em todos os itens fechados enviadas com menos de 10 minutos de diferença, e mantemos só a primeira.

Para as perguntas nominais usaremos frequências e proporções, sempre com a margem de erro. Para os itens Likert usaremos mediana e intervalo interquartil, com gráfico de barras divergentes.

Os itens invertidos (UP4 e CD3) serão recodificados como 6 menos o valor marcado. O índice de cada construto é a média dos seus itens, e a confiabilidade será medida pelo alfa de Cronbach, aceitável a partir de 0,70. Se ficar abaixo disso, vamos calcular o alfa retirando cada item; a remoção de um item entra como desvio do protocolo. Como os índices vêm de itens ordinais, os testes que os usam são não paramétricos.

Os testes de cada questão foram escolhidos de acordo com a escala das variáveis:

QP	Variáveis	Teste	Tamanho de efeito
QP1	U1: acompanha ou não cada uma das 4 métricas (mesmos respondentes)	Q de Cochran, para ver se as 4 métricas são acompanhadas em proporções diferentes; se houver diferença, McNemar par a par	η^2 de Cochran = $Q / (n(k - 1))$; razão de chances nos pares
QP1	U2, U3, U4, CD1 a CD3 e A1	Descritiva: proporções com margem de erro, mediana do índice de confiança e contagem das categorias da A1	Não se aplica

QP	Variáveis	Teste	Tamanho de efeito
QP2	Porte da empresa (P3) e adoção (U0), sem as respostas "Não sei"	Qui-quadrado de independência, ou exato de Fisher se alguma frequência esperada for menor que 5	V de Cramér
QP3	Utilidade percebida (M6) e papel (P1)	Kruskal-Wallis, com pós-teste de Dunn se houver diferença	Épsilon ao quadrado
QP3	Utilidade percebida (M6) e número de métricas (M7)	Correlação de Spearman	Rho de Spearman

O nível de significância é 0,05. Os p-valores dos quatro testes principais (Cochran, qui-quadrado, Kruskal-Wallis e Spearman) serão corrigidos pelo método de Holm. Os pós-testes (McNemar e Dunn) terão uma correção de Holm própria, dentro de cada conjunto de comparações. Se algum grupo tiver menos de 5 respostas, ele será juntado com outro antes do teste (por exemplo, QA com Outro, ou as faixas de porte em "até 249" e "250 ou mais"), e isso será indicado no dashboard.

Na pergunta aberta, dois integrantes vão criar categorias separadamente e depois comparar até chegar a um consenso. O resultado aparece como contagem por categoria. Toda a análise parte da exportação bruta da planilha do formulário, que é a mesma fonte lida pelo dashboard.

6. Ética e LGPD

A pesquisa é anônima. A primeira página do formulário traz o termo de consentimento, que explica o objetivo, o tempo de resposta, que a participação é voluntária, que a pessoa pode desistir a qualquer momento fechando a página (nada é gravado antes do envio), que os dados são só para uso acadêmico e como falar com o grupo. Só continua quem aceitar.

O Google Forms está configurado para não coletar e-mail e sem o limite de uma resposta por pessoa, que exigiria login. Não perguntamos o nome da pessoa nem o da empresa. Se alguma resposta aberta citar nomes, eles serão apagados antes da análise. A planilha original fica numa pasta do Google Drive acessível só aos integrantes. No repositório e no dashboard vai apenas a versão anonimizada, e os dados brutos serão apagados quando a disciplina acabar. As evidências da coleta (exportação com data e hora e prints da divulgação) não mostram nenhum dado pessoal.

Seguimos as orientações da PUC Minas para pesquisas com pessoas. Por ser uma pesquisa de opinião com participantes não identificados, entendemos que ela se enquadra no art. 1º, parágrafo único, inciso I, da Resolução CNS nº 510/2016, que dispensa o registro no sistema CEP/Conep. Se o professor ou a instituição orientarem de outra forma, seguiremos a orientação.

7. Ameaças à validade

A maior limitação é a amostra por conveniência: os resultados dizem respeito a quem respondeu e não podem ser generalizados para todos os times com CI/CD do Brasil. As outras ameaças e o que pretendemos fazer estão na tabela.

Ameaça	Tipo	Como vamos mitigar
Autosseleção (quem já gosta de métricas tende a responder mais)	Externa	Divulgar como pesquisa sobre CI/CD, sem destacar DORA no convite, e usar canais variados
Amostra concentrada na rede dos integrantes	Externa	Bola de neve e comunidades de outras regiões; o perfil da amostra aparece no dashboard
Não resposta	Externa	Formulário curto, dois lembretes durante a coleta e link encurtado com contagem de cliques, para comparar quantas pessoas abriram o link com quantas responderam
Desejabilidade social (dizer que usa mais métricas do que usa)	Construto	Reforçar o anonimato no termo e oferecer "Não" e "Não sei" nas perguntas de uso

Ameaça	Tipo	Como vamos mitigar
Pessoas entenderem as métricas de jeitos diferentes	Construto	Explicação curta de cada métrica no formulário, verificada no pré-teste
Construtos mal medidos	Construto	Vários itens por construto, itens invertidos e alfa de Cronbach
Pré-teste feito com colegas da turma, que podem reagir diferente de profissionais	Construto	Escolher colegas que trabalham ou estagiam em times com CI/CD; problemas que aparecerem na coleta serão registrados como desvio
Respostas sem atenção	Interna	Pergunta de atenção e descarte de respostas com padrão repetido
Mais de uma pessoa do mesmo time	Interna	Não temos como controlar; fica declarada como limitação
Falsos positivos por fazer vários testes	Conclusão	Correção de Holm nos testes e nos pós-testes, e tamanho de efeito junto com o p-valor

8. Divulgação e período de coleta

A coleta vai de 13/11 a 23/11/2026 e só começa depois da entrega deste protocolo, em 12/11. A divulgação será feita no LinkedIn dos integrantes (post e mensagem direta), em grupos de desenvolvedores no WhatsApp, Telegram e Discord, com colegas de trabalho e estágio e com ex-alunos do curso. Todo convite pede para a pessoa repassar o link, e todos usam o mesmo link encurtado para que os cliques possam ser contados.

Data	O que será feito
12/11	Pré-teste, ajustes no formulário, separação das respostas do pré-teste, entrega da Parte 1 e commit do protocolo no repositório
13 a 16/11	Início da divulgação
17 a 19/11	Primeiro lembrete e contagem parcial das respostas
20 a 23/11	Segundo lembrete; se houver menos de 50 respostas válidas, divulgar em outros canais (registrado como desvio)
24 e 25/11	Limpeza, análise e montagem do dashboard
26/11 (12h)	Entrega da Parte 2
26/11/2026	Apresentação

Cada divulgação terá um print com a data visível, para servir de evidência da coleta.